

Διαχείριση Δεδομένων Μεγάλου Όγκου

6

ΤΣΙΛΙΜΠΩΚΟΣ ΣΠΥΡΙΔΩΝ ais25118@hua.gr

Αθήνα 2025

Περιεχόμενα

Project's Notebook	3
Pipeline Architecture	3
Design Decisions & Rationale/Implementation Details	4
Βήμα 1:	4
Βήμα 2	4
Βήμα 3 & 4	5
Experimental Setup & Parameter Choices	5
Quantitative Results.....	5
Ανάλυση Dataset A: Fodors-Zagat (Εστιατόρια)	5
Ανάλυση Dataset B: DBLP-ACM (Βιβλιογραφία)	6
Sensitivity Analysis Observations:	6
Fodors Αποτελέσματα	6
Fodors Histogram	7
Fodors Precision/Recall	7
DBLP Αποτελέσματα	8
DBLP Histogram	9
DBLP Precision/Recall	9
Discussion (Limitations & Future Ideas)	10
High Recall:	10
Πείραμα Υβριδικής Ομοιότητας (Hybrid Similarity Experiment)	10
Future Work:	10
Τελικά Συμπεράσματα & Σχεδιαστικές Επιλογές	10
References.....	10

Πίνακας Εικόνων

Pipeline Architecture	3
Fodors Histogram	7
Fodors Precision/Recall	7
DBLP Histogram	9
DBLP Precision/Recall	9


Πίνακες

Main Pipeline Results	6
10 αποτελέσματα ζευγαριών DataSet Fodors.....	6
Πίνακας Αποτελεσμάτων Fodors.....	7
10 αποτελέσματα ζευγαριών DataSet DBLP	8
Πίνακας Αποτελεσμάτων DBLP	9

Σκοπός της παρούσας εργασίας είναι ο σχεδιασμός και η υλοποίηση ενός ολοκληρωμένου συστήματος ER (End-to-End Pipeline) με χρήση του πλαισίου κατανεμημένης επεξεργασίας **Apache Spark**. Η προσέγγισή μας εστιάζει στην εξισορρόπηση μεταξύ υπολογιστικής αποδοτικότητας και ακρίβειας αποτελεσμάτων. Μέσω της εφαρμογής τεχνικών προεπεξεργασίας κειμένου, **Token Blocking** και υπολογισμού ομοιότητας συνόλων (**Jaccard Similarity**), επιδιώκουμε την αποτελεσματική ταυτοποίηση οντοτήτων σε δεδομένα εστιατορίων και βιβλιογραφίας, ελαχιστοποιώντας τον χρόνο εκτέλεσης και μεγιστοποιώντας τις μετρικές Precision και Recall.

Project's Notebook

Pipeline Architecture



1) Pipeline Architecture

Το σχήμα 1 απεικονίζει την αρχιτεκτονική του συστήματος Entity Resolution που υλοποιήσαμε. Η διαδικασία ακολουθεί μια γραμμική ροή (sequential pipeline) επεξεργασίας δεδομένων Spark:

1. **Ingestion:** Αρχικά, τα δεδομένα εισόδου φορτώνονται από αρχεία CSV σε Spark DataFrames.
2. **Preprocessing:** Τα δεδομένα καθαρίζονται, κανονικοποιούνται και μετατρέπονται σε λίστες λέξεων (tokens).
3. **Blocking:** Εφαρμόζεται η τεχνική Token Blocking για τη δημιουργία ζευγών υποψηφίων (Candidate Pairs), μειώνοντας δραστηκά τον χώρο αναζήτησης.
4. **Matching:** Υπολογίζεται η ομοιότητα Jaccard για κάθε ζεύγος και εφαρμόζεται φίλτρο (thresholding) για την τελική ταυτοποίηση.
5. **Output:** Τα αποτελέσματα εξάγονται και αξιολογούνται βάσει του Ground Truth.

Design Decisions & Rationale/Implementation Details

Για την υλοποίηση του ER Pipeline λάβαμε τις εξής σχεδιαστικές αποφάσεις:

Βήμα 1: Data Preprocessing (Προεπεξεργασία) Η ποιότητα των αποτελεσμάτων στο Entity Resolution εξαρτάται άμεσα από την καθαρότητα των δεδομένων εισόδου. Η διαδικασία προεπεξεργασίας υλοποιήθηκε ως εξής:

- **Feature Selection & Concatenation:** Επιλέχθηκαν πεδία με υψηλή διακριτική ικανότητα (discriminative power). Για τα εστιατόρια συνενώσαμε τα name, addr, city, ενώ για τη βιβλιογραφία τα title, authors, venue. Η συνένωση επιτρέπει στον αλγόριθμο να αντιμετωπίσει την πληροφορία ολιστικά, αποφεύγοντας λάθη όταν π.χ. ένα όνομα συγγραφέα έχει μπει κατά λάθος στο πεδίο του τίτλου.
- **Normalization & Cleaning:** Εφαρμόστηκε καθολική μετατροπή σε πεζά (lowercasing) για την εξάλειψη διαφορών κεφαλαιοποίησης. Επιπλέον, χρησιμοποιήσαμε την native συνάρτηση regexp_replace του Spark για την αφαίρεση ειδικών χαρακτήρων και σημείων στίξης, αντικαθιστώντας τα με κενά, ώστε να αποφευχθεί η αλλοίωση των tokens.
- **Stopwords Removal:** Αυτό αποτέλεσε το κρίσιμότερο βήμα για την απόδοση του συστήματος. Λέξεις υψηλής συχνότητας αλλά χαμηλής πληροφοριακής εντροπίας (π.χ. "the", "and", "restaurant", "inc") αφαιρέθηκαν μέσω Regex. Η απουσία αυτού του βήματος στα αρχικά πειράματα οδηγούσε σε εκθετική αύξηση των υποψηφίων ζευγών (data skewness), καθώς χιλιάδες εγγραφές συνδέονταν λανθασμένα μέσω κοινών λέξεων θορύβου.

Βήμα 2: Blocking (Μείωση Χώρου Αναζήτησης) Η αφέλης προσέγγιση σύγκρισης κάθε εγγραφής με όλες τις άλλες (Καρτεσιανό Γινόμενο) έχει πολυπλοκότητα $O(N \times M)$, η οποία είναι απαγορευτική για μεγάλα datasets.

- Υλοποιήσαμε τη στρατηγική **Standard Token Blocking**.
- Μέσω της εντολής explode(), μετασχηματίσαμε τα δεδομένα ώστε κάθε token να αποτελεί κλειδί ευρετηρίασης (Inverted Index).
- Στη συνέχεια, εκτελέστηκε INNER JOIN στα κοινά tokens. Αυτή η διαδικασία περιόρισε δραστηκά τον χώρο αναζήτησης, δημιουργώντας ζεύγη υποψηφίων (Candidate Pairs) μόνο μεταξύ εγγραφών που μοιράζονται τουλάχιστον μία σημασιολογική λέξη.

Βήμα 3 & 4: Representation & Similarity

- Οι οντότητες αναπαραστάθηκαν ως **Σύνολα Λέξεων (Sets of Tokens)**. Αυτή η προσέγγιση (Bag of Words) επιλέχθηκε έναντι των διανυσματικών αναπαραστάσεων (Embeddings) λόγω της απλότητας και της ταχύτητάς της σε περιβάλλον Spark.
- Για τον υπολογισμό της ομοιότητας χρησιμοποιήθηκε ο συντελεστής **Jaccard**: $J(A,B)=|A \cup B|/|A \cap B|$. Η υλοποίηση έγινε με χρήση των `array_intersect` και `array_union` του Spark SQL, εκμεταλλευόμενοι τον Catalyst Optimizer για ταχύτερη εκτέλεση σε σχέση με τις User Defined Functions (UDFs) της Python.

Experimental Setup & Parameter Choices

- Datasets:**
 - Fodors-Zagat:** Δεδομένα εστιατορίων (~500/300 εγγραφές). Πεδία σύγκρισης: name, addr, city.
 - DBLP-ACM:** Δεδομένα βιβλιογραφίας (~2600/2200 εγγραφές). Πεδία σύγκρισης: title, authors, venue.
- Environment:** Google Colab (Standard Instance).
- Threshold Parameter:** Μέσω ανάλυσης ευαισθησίας (Sensitivity Analysis), ορίσαμε το κατώφλι ομοιότητας (Matching Threshold) στο **0.5**. Η τιμή αυτή επέτυχε τη βέλτιστη ισορροπία μεταξύ Precision και Recall (μέγιστο F1 Score).

Η αξιολόγηση πραγματοποιήθηκε σε δύο datasets διαφορετικής φύσης, με στόχο την εξέταση της γενικευσιμότητας (robustness) του αλγορίθμου. Μέσω της **Ανάλυσης Ευαισθησίας (Sensitivity Analysis)**, μελετήσαμε πώς η μεταβολή του κατωφλίου ομοιότητας (threshold) επηρεάζει την ακρίβεια και την ανάκληση.

Quantitative Results

Ανάλυση Dataset A: Fodors-Zagat (Εστιατόρια)

Τα αποτελέσματα ανέδειξαν τις ιδιαιτερότητες των ημι-δομημένων δεδομένων εστιατορίων:

- Το πρόβλημα του Θορύβου (Low Thresholds):** Σε χαμηλά κατώφλια (0.1 - 0.3), παρατηρήσαμε ότι ενώ το Recall είναι 100%, το Precision είναι σχεδόν μηδενικό (0.3%). Αυτό συμβαίνει διότι τα ονόματα εστιατορίων περιέχουν συχνά κοινές λέξεις (π.χ. "Grill", "Cafe", "House"). Το Blocking παράγει πλήθος False Positives που μοιράζονται μόνο αυτές τις κοινές λέξεις, καθιστώντας απαραίτητο ένα αυστηρό φίλτρο ομοιότητας.
- Η φύση των Διπλοτύπων (High Thresholds):** Παρατηρήθηκε απότομη πτώση του Recall (από 95% σε 70%) όταν το κατώφλι αυξήθηκε από 0.5 σε 0.7. Αυτό υποδεικνύει ότι τα πραγματικά διπλότυπα στο dataset **δεν είναι πανομοιότυπα**. Υπάρχουν σημαντικές λεκτικές διαφοροποιήσεις (π.χ. "Art's Delicatessen" vs "Arts Deli") που παράγουν Jaccard scores στο εύρος [0.5, 0.7].
- Βέλτιστη Επιλογή:** Το κατώφλι **0.5** αναδείχθηκε ως το "Sweet Spot", επιτυγχάνοντας F1-Score **0.8739**, διατηρώντας το Recall σε εξαιρετικά υψηλά επίπεδα (94.5%).

Ανάλυση Dataset B: DBLP-ACM (Βιβλιογραφία)

Η συμπεριφορά στα βιβλιογραφικά δεδομένα ήταν σαφώς διαφορετική και πιο "καθαρή":

- Υψηλή Διαχωριστική Ικανότητα:** Ακόμα και σε χαμηλό κατώφλι (0.3), το Precision εκτοξεύθηκε στο 56% (έναντι 3% στο Fodors). Αυτό οφείλεται στη φύση του πεδίου Title: οι τίτλοι επιστημονικών άρθρων αποτελούνται από μακροσκελείς, μοναδικές ακολουθίες λέξεων. Είναι στατιστικά απίθανο δύο άσχετα άρθρα να μοιράζονται το 30% των λέξεων του τίτλου τους τυχαία.
- Αποτελέσματα:** Ο αλγόριθμος πέτυχε εξαιρετική απόδοση με F1-Score **0.9192** στο κατώφλι 0.5. Η πτώση του Recall σε πολύ υψηλά κατώφλια (>0.9) επιβεβαιώνει ότι ακόμα και εδώ υπάρχουν μικρές διαφοροποιήσεις (π.χ. στη λίστα συγγραφέων ή στη συντομογραφία του συνεδρίου), οι οποίες όμως αντιμετωπίζονται επιτυχώς από την ελαστικότητα του Jaccard.

Τα πειράματα έδειξαν ότι ο αλγόριθμος είναι ιδιαίτερα αποδοτικός και στα δύο datasets.

Table 1) Main Pipeline Results

Dataset	Precision	Recall	F1-Score	Time (sec)
Fodors-Zagat	0.8125	0.9455	0.8739	~4.4s
DBLP-ACM	0.8879	0.9527	0.9192	~46.0s

Sensitivity Analysis Observations:

- Στο dataset **DBLP-ACM**, παρατηρήσαμε ότι ακόμα και σε χαμηλά κατώφλια (0.3), το Precision παραμένει υψηλό (>50%), λόγω της μοναδικότητας των τίτλων των άρθρων.
- Αντίθετα, στο **Fodors-Zagat**, χαμηλά κατώφλια οδηγούν σε πολύ χαμηλό Precision, καθώς πολλά εστιατόρια μοιράζονται κοινές λέξεις (π.χ. "Grill", "Cafe") χωρίς να είναι ίδια.

Fodors Αποτελέσματα


Table 2) 10 αποτελέσματα ζευγαριών DataSet Fodors

ltable_id	Left_name	rtable_id	Right_name	jaccard
0	` arnie morton \ 's of chicago '	218	` arnie morton \ 's of chicago '	0.8181818181818182
1	` art \ 's delicatessen '	219	` art \ 's deli '	0.7777777777777778
2	` hotel bel-air '	220	` bel-air hotel '	1.0
3	` cafe bizou '	221	` cafe bizou '	1.0
4	campanile	222	campanile	1.0
5	` chinois on main '	223	` chinois on main '	1.0
6	citrus	224	citrus	1.0
7	fenix	225	` fenix at the argyle '	0.625
8	granita	226	granita	1.0
10	` restaurant katsu '	228	katsu	0.5555555555555556


Fodors Histogram

2) Fodors Histogram

ΑΝΑΛΥΣΗ & ΓΡΑΦΗΜΑΤΑ ΓΙΑ: FODORS
Δημιουργία Ιστογράμματος...



Fodors Precision/Recall



3) Fodors Precision/Recall

Table 3) Πίνακας Αποτελεσμάτων Fodors


	Threshold	Precision	Recall	F1
0	0.1	0.003130	1.000000	0.006241
1	0.3	0.032286	1.000000	0.062553
2	0.5	0.561497	0.954545	0.707071
3	0.7	0.962963	0.709091	0.816754
4	0.9	1.000000	0.363636	0.533333

DBLP Αποτελέσματα

Table 4) 10 αποτελέσματα ζευγαριών DataSet DBLP


table_id	Left_title	rtable_id	Right_title	jaccard
0	semantic integration of environmental models for application to global information systems and decision-making	117	semantic integration of environmental models for application to global information systems and decision-making	0.9375
1	estimation of query-result distribution and its application in parallel-join load balancing	1093	estimation of query-result distribution and its application in parallel-join load balancing	0.75
3	cost-based selection of path expression processing algorithms in object-oriented databases	1125	cost-based selection of path expression processing algorithms in object-oriented databases	0.782608695652174
4	benchmarking spatial join operations with spatial output	1450	benchmarking spatial join operations with spatial output	0.6666666666666666
5	efficient geometry-based similarity search of 3d spatial databases	49	efficient geometry-based similarity search of 3d spatial databases	0.7333333333333333
7	enhanced abstract data types in object-relational databases	1179	enhanced abstract data types in object-relational databases	0.625
8	report on dart '96 : databases : active and real-time (concepts meet practice)	1759	report on dart '96 : databases : active and real-time (concepts meet practice)	0.9411764705882353
9	unisql 's next-generation object-relational database management system	1885	unisql 's next-generation object-relational database management system	0.9411764705882353
10	dual-buffering strategies in object bases	2289	dual-buffering strategies in object bases	0.6923076923076923

DBLP Histogram



4) DBLP Histogram

DBLP Precision/Recall



5) DBLP Precision/Recall

Table 5) Πίνακας Αποτελεσμάτων DBLP

	Threshold	Precision	Recall	F1
0	0.1	0.011414	1.000000	0.022571
1	0.3	0.562262	0.998649	0.719455
2	0.5	0.869547	0.960811	0.912904
3	0.7	0.953686	0.658559	0.779110
4	0.9	0.990610	0.095045	0.173448

Discussion (Limitations & Future Ideas)

High Recall: Το υψηλό Recall (>94%) και στις δύο περιπτώσεις αποδεικνύει ότι η στρατηγική Token Blocking ήταν επιτυχής και δεν "έχασε" πληροφορία.

Πείραμα Υβριδικής Ομοιότητας (Hybrid Similarity Experiment) Στα πλαίσια της βελτιστοποίησης του Pipeline, διερευνήσαμε τη χρήση μιας υβριδικής μετρικής που συνδυάζει το **Token-based Jaccard** με το **Character-based Levenshtein Distance**.

- **Παρατήρηση:** Εφαρμόζοντας τη μέθοδο στο Fodors dataset, το Recall αυξήθηκε οριακά στο **97.3%**, ωστόσο το Precision κατέρρευσε στο **19%**.
- **Αιτιολόγηση:** Η απόσταση Levenshtein, όταν εφαρμόζεται στο συνολικό string της εγγραφής, επηρεάζεται δυσανάλογα από πεδία που επαναλαμβάνονται, όπως η Πόλη και η Διεύθυνση. Δύο διαφορετικά εστιατόρια που συστεγάζονται (π.χ. σε ένα εμπορικό κέντρο) έχουν σχεδόν ίδια διεύθυνση, με αποτέλεσμα το Levenshtein να παράγει υψηλό σκορ ομοιότητας, αγνοώντας τη διαφορά στο Όνομα.
- **Συμπέρασμα:** Για datasets όπου η διαφοροποίηση εντοπίζεται σε μικρό τμήμα της συμβολοσειράς (στο Όνομα), η προσέγγιση συνόλων (Jaccard) είναι ανώτερη και πιο στιβαρή από την προσέγγιση χαρακτήρων.

Το πείραμα αυτό ανέδειξε μια βασική αρχή του Entity Resolution: **Δεν υπάρχει 'One-size-fits-all' μετρική**. Για μικρά strings με υψηλή ομοιότητα 'θορύβου' (όπως κοινές διευθύνσεις εστιατορίων), οι μετρικές χαρακτήρων (Levenshtein) παράγουν ψευδώς θετικά αποτελέσματα, καθιστώντας τις μετρικές συνόλων (Jaccard) πιο ασφαλείς.

Future Work: Μελλοντικά, θα μπορούσε να χρησιμοποιηθεί **Meta-Blocking** για περαιτέρω μείωση των υποψήφιων ζευγών ή χρήση **Word Embeddings** για την ταυτοποίηση συνωνύμων (π.χ. "Asian" = "Oriental") που το Jaccard αδυνατεί να εντοπίσει.

Τελικά Συμπεράσματα & Σχεδιαστικές Επιλογές

Η επιτυχία της υλοποίησης βασίστηκε σε τρεις πυλώνες:

1. **Καταλληλότητα Jaccard:** Η επιλογή της σύγκρισης tokens αποδείχθηκε ιδανική για textual data, προσφέροντας ανθεκτικότητα σε αναγραμματισμούς και μικρά λάθη, όπως φάνηκε από τα υψηλά F1 Scores (>0.87).
2. **Βελτιστοποίηση Spark:** Η αποφυγή Python loops και η χρήση native Spark functions εξασφάλισαν χαμηλούς χρόνους εκτέλεσης (~4s για Fodors, ~45s για DBLP), καθιστώντας τη λύση scalable.
3. **Διαχείριση Stopwords:** Η αφαίρεση λέξεων θορύβου ήταν καθοριστική για την αποφυγή της έκρηξης του χώρου αναζήτησης και τη διατήρηση της χρήσης μνήμης σε λογικά επίπεδα.

References

- Christen, P. (2012). Data Matching: Concepts and Techniques for Record Linkage, Entity Resolution, and Duplicate Detection. Springer.
- Apache Spark Documentation: <https://spark.apache.org/docs/latest/api/python/>
- Datasets Source: <https://github.com/anhaidgroup/deepmatcher/blob/master/Datasets.md> (Fodors-Zagat, DBLP-ACM).